



INTELIGENCIA ARTIFICIAL PARA DIAGNÓSTICO TEMPRANO DE ALZHEIMER


POLITÉCNICA

Elsa Martínez Báez, ETSIT UPM, elsa.martinez.baez@alumnos.upm.es
Ignacio Martínez-Almeida Nistal, ETSIT UPM, i.mnistal@alumnos.upm.es
Daniel Roldán Herrero, ETSIT UPM, daniel.roldanh@alumnos.upm.es

Imágenes Biomédicas Avanzadas II, GIB, ETSIT UPM

INTRODUCCIÓN

El Alzheimer es la forma más común de demencia entre las personas mayores. Es incurable y terminal, aparece con mayor frecuencia en personas mayores de 65 años de edad. El reto principal en el empleo de métodos computacionales para el diagnóstico de la enfermedad es adquirir los datos de neuroimagen de las diferentes modalidades ya que no todos los sujetos tienen todas las modalidades de imagen. La eficacia del diagnóstico de imágenes podría ser mejorada si los datos que faltan pudieran ser estimados. Sin embargo, esta relación entre las diferentes modalidades de datos es complicada y no lineal. Se investigará el uso de redes neuronales convolucionales profundas (CNN: deep convolutional neural networks) para estimar una imagen PET partiendo de una resonancia magnética (RM). Se buscará el éxito de este método para poder implementarlo en el diagnóstico temprano de la enfermedad del Alzheimer.



METODOLOGÍA

PREPROCESADO

Las imágenes utilizadas son imágenes de RM e imágenes PET de 830 sujetos que se utilizarán para realizar una comparativa posterior. Las imágenes de resonancia se segmentan en mapas de densidad de sustancia gris, sustancia blanca y líquido cefalorraquídeo y se normalizan. Se mejora la relación señal-ruido mediante un suavizado gaussiano y se realiza un *downsampling* en PET y en el mapa de la materia gris en 64x64x64 vóxeles.


	Pacientes con Alzheimer	MCI* progresivo	MCI* estable	Grupo control
<i>n</i>	198	167	236	229

Tabla 1. Selección de sujetos

*El término MCI se refiere a aquellos pacientes que presentan daños leves cognitivos sin llegar a padecer Alzheimer.

ALGORITMO 3D-CNN

En este trabajo se utiliza una red neuronal de este tipo para realizar un mapeado no lineal entre imágenes de RM y PET mediante convoluciones con filtros 3D. Las CNN son redes neuronales profundas artificiales que se usan principalmente para clasificar imágenes, agruparlas por similitud y realizar el reconocimiento de objetos dentro de las escenas. Se usarán imágenes RM para estimar PET.



Para entrenar el algoritmo se han utilizado fracciones de los volúmenes completos de imágenes de RM y PET de 398 de los sujetos, aquellos que tenían ambas pruebas de imagen. El tamaño de las fracciones RM de entrada es de 15x15x15 vóxeles (50.000 por volumen) y cada una tiene una fracción PET asociada.

Existen 2 etapas intermedias en las que se realizan convoluciones con filtros 7x7x7 para finalmente dar resultado a la fracción 3x3x3 del volumen PET correspondiente. Se ha elegido esta red neuronal porque es potente y sin coste computacional excesivo. Se entrenó la red durante 10 épocas (medida del número de veces que se usan todos los vectores de entrenamiento una vez para actualizar los pesos), ya que el rendimiento parece haber convergido después de 10 épocas. En total se usaron 19,9 millones de fracciones para el entrenamiento.

CONCLUSIÓN

- Se ha desarrollado un modelo CNN 3D para completar e integrar datos de imágenes neuronales multimodales. Este modelo predice los datos volumétricos de una modalidad de salida a partir de otra diferente de entrada de forma exitosa en la fase de MCI de la enfermedad.
- Esta relación no lineal entre los datos de diferentes modalidades es capturado por un gran número de parámetros entrenables en la red. Se aplica este modelo para predecir los patrones PET que faltan de los datos MRI. Al aplicar este algoritmo se han obtenido unos resultados bastante prometedores.
- Se ha empleado una CNN con dos capas debido al alto coste computacional del entrenamiento.
- Se espera que estos resultados impulsen una mayor investigación en el uso de algoritmos de *machine learning* para conseguir un diagnóstico más temprano de la enfermedad del Alzheimer y no cuando ya se ha diagnosticado MCI.

RESULTADOS

El experimento se centra en evaluar el uso del método 3D-CNN para completar la información perdida de las imágenes PET. La eficacia de este método se comparará con los algoritmos K-nearest neighbour (KNN) y Zero.

RESULTADOS CUANTITATIVOS

Se han realizado dos evaluaciones, la primera usando los 398 sujetos con ambas pruebas de imagen y la segunda con todos los sujetos. Las siguientes tablas se obtienen del cálculo de AUC (área por debajo de la curva ROC).

Tasks	MCI vs. NC	pMCI vs. sMCI	AD vs. NC
True data	0.7014 ± 0.0212	0.6823 ± 0.0241	0.8982 ± 0.0224
3-D CNN	0.6947 ± 0.0281	0.6804 ± 0.0267	0.8868 ± 0.0208
KNN	0.6304 ± 0.0248	0.6278 ± 0.0326	0.7421 ± 0.0282
Zero	0.6175 ± 0.0213	0.6124 ± 0.0243	0.6928 ± 0.0225

Tabla 2. Resultados de la primera evaluación


Tasks	MCI vs. NC	pMCI vs. sMCI	AD vs. NC
MRI	0.7439 ± 0.0329	0.7168 ± 0.0253	0.9192 ± 0.0188
3-D CNN	0.7305 ± 0.0315	0.7029 ± 0.0245	0.8762 ± 0.0236
KNN	0.6352 ± 0.0200	0.6133 ± 0.0346	0.7391 ± 0.0304
Zero	0.6102 ± 0.0268	0.5924 ± 0.0331	0.7028 ± 0.0331
3-D CNN	0.7621 ± 0.0205	0.7244 ± 0.0241	0.9287 ± 0.0207
KNN	0.7231 ± 0.0214	0.6813 ± 0.0312	0.7691 ± 0.0213
Zero	0.7217 ± 0.0290	0.6291 ± 0.0317	0.7003 ± 0.0162

Tabla 3. Resultados de la segunda evaluación

Evaluando las AUC de los diferentes métodos se obtiene que el 3D-CNN es más preciso que con los métodos KNN y Zero. Además, se extraen correctamente las relaciones no lineales.

RESULTADOS CUALITATIVOS

Se puede observar cualitativamente la buena aproximación de las imágenes del método 3-D CNN en los diferentes tipos de paciente y esto confirma que el algoritmo estima con éxito los datos PET que faltaban. Los resultados finales pueden ser peores que los que se podrían obtener con toda la información de la base de datos. Asimismo, no se ha hecho una extracción de características avanzadas ni se han utilizado todos los pacientes para entrenar. Esto sugiere que el método presentado tiene un uso potencial en la mejora de la precisión del diagnóstico de la enfermedad.



Referencias

- [1]. Li Rongjian, Zhang Wenlu, Suk Heung-Il, Wang Li, Li Jiang, Shen Dinggang, and Ji Shuiwang. 2014. Deep Learning Based Imaging Data Completion for Improved Brain Disease Diagnosis. In Proceedings of the 17th International Conference on Medical Image Computing and Computer Assisted Intervention 305–312.
- [2]. Xiaonan Liu, Kewei Chen, Teresa Wu, David Weidman, Fleming Lure, Jing Li. 2018. Use of multi-modality imaging and artificial intelligence for diagnosis and prognosis of early stages of Alzheimer's disease, Translational Research.